

学号 20235937

密级

东北大学本科毕业生毕业设计（论文）

面向可解释自动驾驶规划的 神经回路策略拓扑优化

学院名称：计算机科学与工程学院

专业名称：计算机科学与技术

学生姓名：孙家恒

指导教师：卢炳先副教授

二〇二六年五月

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：_____

日期：_____

摘要

自动驾驶规划系统面临计算效率、可解释性合规和长尾泛化三大挑战。当前端到端大模型参数量巨大、不可解释,难以满足边缘部署和安全认证需求。神经电路策略(NCP)以极少参数和生物启发的稀疏结构提供了一条差异化路径,但其布线拓扑完全依赖手工设计,且在强化学习场景下的适用性尚未得到验证。

本文提出一种基于NCP的可解释自动驾驶规划方法。首先,将NCP集成为Double DQN的Q-network,针对NCP的ODE约束导致的表达能力瓶颈,提出两层Q-head方案,在保持液态动力学可解释性的同时实现有效的Q值估计。其次,设计面向NCP布线拓扑的进化搜索算法,采用安全感知的多目标适应度函数,在highway-v0场景上自动发现兼顾性能与安全性的最优布线方案。

在Highway-env的4个驾驶场景上,与随机策略、MLP、LSTM、GRU、全连接LTC共5种基线模型进行了系统对比实验。结果表明,NCP以7,152个参数在高速公路场景上取得了与13,189参数的MLP相当的奖励(34.94对34.88),参数效率约为GRU的3倍,且在所有学习模型中方差仅次于全连接LTC(1.21对1.10)、显著低于MLP/GRU/LSTM。与同参数量的全连接LTC相比,NCP的结构化稀疏拓扑在奖励上提升了23%。多层次可解释性分析揭示了NCP命令层神经元与驾驶决策之间的对应关系。

关键词: 神经电路策略; 液态时间常数网络; 自动驾驶规划; 拓扑搜索; 可解释人工智能

ABSTRACT

Autonomous driving planning systems face three major challenges: computational efficiency, interpretability compliance, and long-tail generalization. Current end-to-end large models are parameter-heavy and opaque, making them unsuitable for edge deployment and safety certification. Neural Circuit Policies (NCP), with their minimal parameters and biologically-inspired sparse structure, offer a differentiated approach, but their wiring topology relies entirely on manual design, and their applicability in reinforcement learning scenarios remains unverified.

This thesis proposes an interpretable autonomous driving planning method based on NCP. First, NCP is integrated as the Q-network of Double DQN. To address the expressivity bottleneck caused by NCP's ODE constraints, a two-layer Q-head scheme is proposed, enabling effective Q-value estimation while preserving the interpretability of liquid dynamics. Second, an evolutionary search algorithm for NCP wiring topology is designed with a safety-aware fitness function on the highway-v0 scenario, automatically discovering wiring configurations that balance performance and safety.

Systematic experiments are conducted on four driving scenarios in Highway-env, comparing against five baseline models: random policy, MLP, LSTM, GRU, and fully-connected LTC. Results show that NCP achieves comparable reward to MLP (34.94 vs 34.88) on the highway scenario with only 7,152 parameters (vs 13,189), achieving roughly 3x the parameter efficiency of GRU. Among all learning models, NCP exhibits the second-lowest reward variance on highway-v0 (1.21), behind only fully-connected LTC (1.10) and well below MLP/GRU/LSTM. Compared

with fully-connected LTC at the same parameter count, NCP's structured sparse topology improves reward by 23%. Multi-level interpretability analysis reveals the correspondence between NCP command neurons and driving decisions.

Key words: Neural Circuit Policies; Liquid Time-Constant Networks; Autonomous Driving Planning; Topology Search; Explainable Artificial Intelligence

目 录

1	绪论	1
1.1	课题背景及目的	1
1.2	国内外研究状况	2
1.2.1	国外研究现状	2
1.2.2	国内研究现状	3
1.3	本文的研究内容和技术路线	4
1.4	本章小结	6
2	相关技术	7
2.1	液态时间常数网络	7
2.2	神经电路策略	8
2.3	深度 Q 网络与 Double DQN	9
2.4	进化搜索算法	10
3	基于神经电路策略的可解释规划方法	12
3.1	整体框架	12
3.2	神经电路策略 Q 网络设计	14
3.3	安全感知的布线拓扑搜索	16
3.3.1	搜索空间与约束	16
3.3.2	安全感知适应度函数	16
3.3.3	搜索流程	17

3.3.4 搜索结果	17
4 实验与分析	18
4.1 实验设置	18
4.1.1 仿真环境	18
4.1.2 观测空间	18
4.1.3 对比模型	18
4.1.4 训练配置	19
4.2 基线对比实验	19
4.2.1 主要发现	22
4.3 消融实验	23
4.3.1 布线拓扑搜索结果	23
4.3.2 搜索拓扑的结构分析	24
4.3.3 ODE 展开数消融实验	25
4.4 可解释性分析	27
4.4.1 参数效率分析	27
4.4.2 命令神经元激活分析	27
4.4.3 神经元功能归因	28
4.4.4 跨场景激活模式对比	29
4.4.5 结构可解释性讨论	30
5 结论与展望	32
5.1 结论	32
5.2 展望	32

参考文献	37
致谢	38
附录	40

1 绪论

1.1 课题背景及目的

自动驾驶规划系统负责根据感知信息生成安全、高效的驾驶轨迹，是自动驾驶技术栈中的核心环节。近年来，该领域经历了从传统模块化流水线向端到端学习的范式转变。UniAD^[1]、VAD^[2]、DriveTransformer^[3] 等端到端 Transformer 模型在 nuScenes^[4] 等基准上取得了领先性能，推动了感知-预测-规划的联合优化。

然而，当前自动驾驶规划仍面临三大核心挑战。其一，**计算效率**问题：端到端大模型参数量巨大，难以在车端边缘设备上实时部署，而 L2 级自动驾驶系统要求端到端延迟在 20–100ms 之内。其二，**可解释性与安全合规**问题：欧盟《人工智能法案》将于 2026 年 8 月全面执行^[5]，自动驾驶系统被归类为高风险 AI 系统，要求具备可追溯性和可解释性；当前端到端黑箱模型无法满足这一合规要求^[6]。其三，**长尾场景泛化**问题：模型在分布外罕见场景下表现不稳定，难以保证安全性。

与此同时，生物启发的液态神经网络展示了独特潜力。Lechner、Hasani 等人^[7]提出的神经电路策略 (Neural Circuit Policies, NCP) 受秀丽隐杆线虫神经连接组^[8]启发，仅用 19 个神经元和 253 个突触即可完成自动驾驶车道保持任务，参数量比传统 LSTM 网络少数个数量级，且注意力自动聚焦道路关键区域，具备内在可解释性。后续工作包括闭式连续时间网络 CfC^[9]（将推理速度提升 5–8 倍）和 Liquid-S4^[10]（实现并行训练），最终演化为 Liquid AI 公司的 LFM 系列大模型^[11]。

然而，NCP 的四层布线拓扑（感觉层 → 中间层 → 命令层 → 运动层）目前完全依赖

手工设计，缺乏系统化的优化方法。此外，NCP 在强化学习场景下的适用性尚未得到充分验证——其 ODE 动力学约束（权重非负、稀疏连接、固定极性）是否与 Q-value 估计兼容，是一个未被探索的问题。

基于上述背景,本文提出将 NCP 作为自动驾驶规划的轻量可解释 Planning Head,设计进化搜索算法自动优化其布线拓扑,并在 Highway-env^[12] 仿真平台上进行系统验证。本研究旨在回答以下问题: (1) NCP 能否以极少参数量达到甚至超越传统 MLP/LSTM/GRU 的决策性能? (2) 能否通过自动化搜索发现比手工设计更优的 NCP 布线拓扑? (3) NCP 的结构化稀疏连接是否带来可量化的性能和安全性优势?

1.2 国内外研究状况

1.2.1 国外研究现状

端到端自动驾驶规划方面, UniAD^[1] (CVPR 2023 最佳论文) 首次将检测、跟踪、建图、运动预测和规划统一在 Transformer 框架中, 在 nuScenes 规划基准上取得 L2 误差 0.71m。VAD^[2] 用向量化场景表示替代稠密栅格, 显著降低计算开销。SparseDrive^[13] 采用全稀疏架构实现感知-规划端到端。DriveTransformer^[3] (ICLR 2025) 提出任务间双向交互的 Transformer 架构, 成为端到端规划的最新代表。2025 年, 稀疏表示与端到端联合优化已成为主流范式。

大模型驱动的规划方面, EMMA^[14] (Waymo, 基于 Gemini) 将端到端驾驶统一为视觉-语言生成任务。DriveVLM^[15] 结合视觉语言模型的链式推理与传统规划器, 实现双系统架构。扩散模型规划方面, DiffusionDrive^[16] (CVPR 2025) 通过截断扩散实现高效多模态轨迹生成。强化学习方面, CaRL^[17] 采用大规模 PPO 训练超越了此前所有方法。然而, 上述方法均面临推理延迟高、参数量大、可解释性不足等共同挑战。

液态神经网络方面, Hasani 等人^[18]提出的液态时间常数网络 (LTC) 通过输入自适应的 ODE 动力学实现高效时序建模。NCP^[7] 将 LTC 与生物启发的四层稀疏布线结合, 以极少参数实现车道保持。CfC^[9] 用闭式解替代 ODE 求解器, 将推理速度提升 5–8 倍。Chahine 等人^[19] 在 *Science Robotics* 上展示了仅 19 个神经元的 NCP 在分布外飞行导航中远超大型网络的鲁棒性。Liquid AI 在 2025 年发布了 LFM2 系列模型^[11], 完成了从 ODE 动力学到门控短卷积 +GQA 混合架构的演进。

神经架构搜索方面, NEAT^[20] 专门针对网络拓扑的进化搜索, DARTS^[21] 将搜索时间从数千 GPU 天降至数天。然而, 面向 NCP 布线拓扑的自动化搜索尚属空白。

深度强化学习方面, DQN^[22] 通过经验回放和目标网络稳定训练, 是离散动作空间的经典方法。Double DQN^[23] 通过解耦动作选择和 Q-value 评估减少过估计。Highway-env^[12] 提供了高速公路、匝道合流、交叉路口、环岛等多种驾驶场景, 是 RL 驾驶研究的标准平台。

1.2.2 国内研究现状

国内在自动驾驶规划领域发展迅速。清华大学 MARS 实验室提出 DriveVLM^[15], 将视觉语言模型的链式推理能力引入驾驶规划。上海交通大学 Thinklab 团队构建了 Bench2Drive^[24] 闭环评测基准, 包含 44 种交互场景和 220 条评测路线, 推动了端到端方法的公平比较。

在产业应用方面, 理想汽车已在量产车上部署视觉-语言-动作 (VLA) 架构; 小鹏汽车的图灵芯片支持 VLA 与自主强化学习模型的运行。中国工信部于 2024 年发布《智能网联汽车准入管理》规定, 要求 L3 及以上自动驾驶系统具备决策可追溯能力, 这与欧盟 AI 法案的要求形成呼应, 进一步推动了可解释自动驾驶的研究需求。

在可解释性研究方面, Atakishiyev 等人^[25] 系统总结了可解释 AI 在自动驾驶领域的

五类贡献；Zablocki 等人^[6]在 IJCV 综述中指出，黑箱模型缺乏因果理解能力是获取监管信任的核心障碍。国内外学者普遍认为，**内在可解释架构**（如 NCP 的结构化稀疏设计）比事后解释方法（如 Grad-CAM）更适合高风险的自动驾驶场景。

综合来看，当前自动驾驶规划领域存在”性能-效率-可解释性”三角困境：高性能模型参数量大、不可解释；轻量模型性能不足；可解释方法多为事后分析，无法提供结构性保证。NCP 以其极少参数、内在可解释性和生物启发的稀疏结构，为打破这一困境提供了可能。

1.3 本文的研究内容和技术路线

本文以神经电路策略（NCP）为核心，围绕”可解释自动驾驶规划”展开研究，主要包括以下四个部分：

(1) NCP 规划头的性能验证。将 NCP 集成为 Double DQN 的 Q-network，针对 NCP 的 ODE 约束问题提出两层 Q-head 方案（用全部神经元隐状态经 MLP 映射 Q-values），在 Highway-env 的 4 个场景（高速巡航、匝道合流、交叉路口、环岛）上与 Random、MLP、LSTM、GRU、全连接 LTC 共 6 种模型进行系统对比。采用 3 个随机种子确保统计显著性，评估维度包括累计奖励、碰撞率、参数量和参数效率。

(2) NCP 布线拓扑的进化搜索。设计结构化搜索空间（6 个离散基因：神经元数量、扇出/扇入度、循环连接数），使用进化策略（锦标赛选择 + 均匀交叉 + 高斯变异）进行搜索。采用安全感知的多目标适应度函数（奖励减去 α 倍碰撞率），在 highway-v0 场景上评估候选个体，自动搜索兼顾性能与安全性的布线方案，并在 merge-v0、intersection-v0 和 roundabout-v0 三个未参与搜索的场景上检验其跨场景泛化能力。

(3) 消融实验。主要包括两组消融：手工拓扑与搜索拓扑的对比（验证布线结构对

NCP 性能的影响)、ODE 展开数消融 (探究精度-效率权衡点)。

(4) 多层次可解释性分析。围绕参数效率、动态、因果和泛化四个维度展开：参数效率层 (参数量-性能帕累托前沿)、动态层 (命令神经元激活与驾驶决策时序对齐)、因果层 (逐神经元 mask 的功能归因矩阵)、泛化层 (跨场景激活 PCA 降维对比)，并结合 NCP 的结构化稀疏布线讨论其内在可解释性优势。

本文的技术路线为：首先在 Highway-env 上搭建统一的实验框架，验证 NCP 的基线性能；然后通过进化搜索优化布线拓扑；接着通过消融实验分析各设计要素的贡献；最后通过多层次可解释性分析展示 NCP 的独特价值。

本文的预期结果包括：(1) NCP 以不到 1 万参数达到与 LSTM、GRU 等传统循环网络相当甚至更优的决策性能，验证其作为轻量规划头的可行性；(2) 进化搜索发现的最优布线拓扑在累计奖励和碰撞率上优于手工设计的默认拓扑；(3) 消融实验定量揭示两层 Q-head、ODE 展开数和网络规模对 NCP 性能的贡献程度；(4) 多层次可解释性分析表明 NCP 的结构化稀疏连接能够产生与驾驶语义对齐的神经元激活模式，为自动驾驶规划系统的安全合规提供结构性支撑。

本文组织结构。全文共分五章：第一章绪论，阐述课题背景、研究意义、国内外研究现状以及本文的研究内容与技术路线；第二章相关技术介绍，系统讲解液态时间常数网络、神经电路策略、深度 Q 网络以及进化搜索算法等核心技术；第三章基于神经电路策略的可解释规划方法，详细论述本文提出的方法框架，包括整体架构、Q-head 解耦设计以及安全感知的布线拓扑搜索算法；第四章实验与分析，在 Highway-env 平台上进行系统的基线对比、搜索实验、消融研究和可解释性分析；第五章总结全文工作并展望未来研究方向。

1.4 本章小结

本章首先阐述了自动驾驶规划领域的三大核心挑战——计算效率、可解释性合规和长尾泛化，指出了当前端到端大模型在边缘部署和安全认证方面的不足。随后，系统梳理了国内外在端到端规划、大模型驱动规划、扩散模型规划、液态神经网络、神经架构搜索和深度强化学习等方向的研究进展。

通过文献调研发现：(1) NCP 以极少参数实现了可解释的自动驾驶控制，但其布线拓扑完全依赖手工设计；(2) NCP 在强化学习 Q-value 估计场景下的适用性尚未被探索；(3) NCP 的结构化稀疏连接相比全连接 LTC 的优势缺乏定量验证。这些研究空白构成了本文的出发点。

2 相关技术

2.1 液态时间常数网络

液态时间常数网络 (Liquid Time-Constant Networks, LTC)^[18] 是一种基于常微分方程的循环神经网络单元。传统 RNN (如 LSTM、GRU) 的门控参数在推理时固定不变, 而 LTC 借鉴了生物神经元的膜电位动力学, 让时间常数 τ 随输入和当前状态动态调整。具体而言, LTC 神经元的状态 x 由以下 ODE 描述:

$$c_m \frac{dx}{dt} = -g_{leak}(x - v_{leak}) + \sum_j w_j \sigma(x_j)(e_{rev,j} - x) \quad (2.1)$$

式中, c_m 为膜电容, g_{leak} 和 v_{leak} 分别为泄漏电导和泄漏电位, w_j 为突触权重, σ 为 sigmoid 激活函数, $e_{rev,j}$ 为第 j 条突触的反转电位。将上式整理可得等价形式 $dx/dt = -[1/\tau(x, I)] \odot x + f(x, I)$, 其中 τ 不再是常数, 而是关于输入 I 和状态 x 的函数——这正是“液态时间常数”名称的由来。

由于上述 ODE 没有解析解, 实现时采用多步欧拉法进行数值离散化, 默认展开 6 步。每一步依次完成三件事: 计算感觉层突触对当前神经元的加权激活、计算循环层突触的加权激活 (需乘以稀疏性掩码以屏蔽不存在的连接), 以及按式 2.1 更新神经元状态。为保证 ODE 动力学的物理合理性, 训练过程中需在每次梯度更新后将 w 、 c_m 、 g_{leak} 裁剪为非负值。

2.2 神经电路策略

神经电路策略 (Neural Circuit Policies, NCP)^[7] 的设计灵感来自秀丽隐杆线虫 (*C. elegans*) 的神经连接组^[8]。秀丽隐杆线虫仅有 302 个神经元, 却能完成趋化、避障等复杂行为, 其关键在于神经元之间高度结构化的稀疏连接模式。NCP 将这一思想迁移到人工神经网络中, 定义了四层布线架构:

感觉层负责接收外部输入特征, 每个输入神经元通过 f_s 条突触向下连接到中间层。中间层对感觉信号进行整合与压缩, 每个中间神经元以 f_i 条突触投射到命令层。命令层是决策的核心, 不仅接收中间层输入, 还具有 r_c 条层内循环连接, 使其能够维持短时记忆。运动层作为输出端, 每个运动神经元从命令层接收 f_m 条突触输入, 生成最终的控制信号。其中 f_s 、 f_i 、 r_c 、 f_m 分别表示感觉扇出、中间扇出、命令循环连接数和运动扇入。

除拓扑结构外, NCP 还为每条突触赋予兴奋性 (+1) 或抑制性 (-1) 的极性属性, 通过邻接矩阵统一编码。实现中, 神经元编号按运动层、命令层、中间层的顺序依次排列。Lechner 等人^[7] 在车道保持任务上的实验表明, 仅 19 个神经元、253 个突触的 NCP 即可完成任務, 而且网络的注意力会自动聚焦到道路边缘等关键区域, 无需额外的可解释性方法就能直观理解网络的决策依据。

图 2.1 展示了一个典型 NCP 的四层布线结构, 其中绿色为感觉层、蓝色为中间层、橙色为命令层、红色为运动层, 实线和虚线分别代表兴奋性和抑制性突触。




图 2.1 NCP 四层稀疏布线拓扑结构示意图

NCP 以 LTC 单元作为每个神经元的动力学模型，因此继承了 LTC 的输入自适应特性。与全连接 LTC 相比，NCP 通过稀疏邻接矩阵限制了信息传播路径。这种限制在参数量上是一种压缩，在功能上则赋予了不同层神经元明确的角色分工——感觉层编码、中间层整合、命令层决策、运动层执行——这是全连接网络所不具备的结构性可解释性。

2.3 深度 Q 网络与 Double DQN

深度 Q 网络 (Deep Q-Network, DQN)^[22] 用神经网络 $Q(s, a; \theta)$ 逼近最优动作值函数，是离散动作空间下深度强化学习的代表性方法。训练目标是最小化时序差分误差：

$$L(\theta) = E_{(s, a, r, s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2.2)$$

其中 $\mathcal{D}$ 为经验回放缓冲区， θ^- 为定期从在线网络复制的目标网络参数， γ 为折扣因子。经验回放打破了连续采样之间的时间相关性，目标网络则避免了“自举目标”随训练

同步漂移导致的振荡。

原始 DQN 存在 Q 值过估计的问题：max 算子同时用于选择和评估动作，会系统性偏高。van Hasselt 等人提出的 Double DQN^[23] 将两者解耦——用在线网络选择最优动作，用目标网络评估其 Q 值：

$$y = r + \gamma Q(s', \arg \max_{a'} Q(s', a'; \theta); \theta^-) \quad (2.3)$$

在本文的场景中，NCP 的 ODE 动力学约束（权重非负、稀疏连接）使得 Q-value 估计的波动本身就比较 MLP 更大，Double DQN 对训练稳定性的帮助更为明显，因此本文统一采用这一方案。

对于循环模型（LSTM、GRU、NCP），训练时不能像 MLP 那样对单步转移独立采样。本文从经验回放缓冲区中抽取长度为 8 的连续序列，序列开头将隐藏状态初始化为零向量，仅对序列最后一步计算损失，以此让隐藏状态有足够的“预热”步数来编码上下文信息。

2.4 进化搜索算法

NCP 的布线拓扑由 6 个离散参数决定：中间神经元数 n_i 、命令神经元数 n_c 、感觉扇出 f_s 、中间扇出 f_i 、命令层循环连接数 r_c 和运动扇入 f_m ，参数之间还存在不等式约束（例如 $f_s \leq n_i$ ）。这类离散、带约束的组合优化问题难以用基于梯度的方法处理，因此本文选择进化搜索算法^[20] 来探索布线空间。

进化搜索模拟自然选择的过程，基本流程为：随机初始化一个由若干布线配置组成的种群，评估每个个体的适应度，然后通过选择、交叉、变异产生下一代，反复迭代直至收敛。本文采用的具体算子如下：

选择阶段使用锦标赛选择，即从种群中随机抽取 k 个个体，取适应度最高者作为父代。 k 值越大，选择压力越强，收敛越快但多样性损失也越大。交叉阶段对两个父代的 6 个基因逐位独立地以概率 0.5 选择来源，拼接为子代基因组。变异阶段对每个基因以概率 p_{mut} 施加高斯扰动 $\Delta \sim \mathcal{N}(0, \sigma^2)$ ，取整后裁剪到该基因的合法范围内。此外，每代保留适应度最高的若干个体直接进入下一代（精英保留），防止已发现的优质解在随机操作中丢失。

需要注意的是，交叉和变异可能产生违反约束的基因组合。例如，若变异后 f_s 超过了 n_i ，则实际构建 NCP 布线时会出错。为此，本文在每次遗传操作后增加一步约束修复，将违约参数裁剪到合法范围。这一设计参考了带约束进化优化的常见做法。

相比可微分架构搜索方法（如 DARTS^[21] 需要将离散选择松弛为连续权重），进化方法直接在离散空间上操作，不需要对搜索空间做连续化近似，实现也更为简单。

3 基于神经电路策略的可解释规划方法

3.1 整体框架

本文提出的方法由三个核心模块组成：基于 NCP 的 Q 网络、Double DQN 训练框架、以及安全感知的布线拓扑进化搜索。整体架构如下：

环境在每个决策步产生一个运动学观测向量（包含自车和周围 4 辆最近车辆的位置、速度和朝向共 35 维特征），经 NCP 的 LTC 动力学处理后输出全部神经元的隐状态，再由两层 Q-head 映射为 5 个离散动作对应的 Q 值。智能体以 ϵ -贪心策略选择动作，与环境交互后将转移存入经验回放缓冲区。训练时从缓冲区采样序列，用 Double DQN 目标更新网络参数。

在此基础上，进化搜索模块对 NCP 的 6 个布线参数进行自动优化。搜索过程中，每个候选布线配置被实例化为一个 NCP Q 网络，快速训练若干步后评估其安全感知适应度，通过选择、交叉、变异迭代优化，最终输出最优布线拓扑。

图 3.1 展示了整体框架的数据流和模块关系。

基于NCP的可解释规划框架




图 3.1 基于 NCP 的可解释规划框架

算法 1给出了本文方法的整体训练流程。

算法 1 基于 NCP 的可解释规划训练流程

输入： 驾驶环境 $\mathcal{E}$, 训练步数 T , 搜索代数 G , 种群大小 N

输出： 训练后的 NCP Q 网络 Q_θ 与最优布线拓扑 g^*

```

1: //阶段一：进化搜索最优布线拓扑
2: 随机初始化布线基因组种群  $\mathcal{P}_0 = \{g_1, \dots, g_N\}$ 
3: for  $gen = 1$  to  $G$  do
4:   for 每个基因组  $g_i \in \mathcal{P}_{gen}$  do
5:     根据  $g_i$  构建 NCP 布线, 实例化 Q 网络
6:     在  $\mathcal{E}$  上快速训练  $T_{fit}$  步
7:     计算适应度  $F(g_i) = \bar{R}(g_i) - \alpha \cdot \bar{C}(g_i)$ 
8:   end for
9:   精英保留, 锦标赛选择父代
10:  交叉、变异、约束修复生成下一代  $\mathcal{P}_{gen+1}$ 
11: end for
12:  $g^* \leftarrow \arg \max_g F(g)$ 
13: //阶段二：基于最优拓扑的完整训练
14: 根据  $g^*$  构建 NCP 布线, 实例化 LTC 单元和两层 Q-head
15: 初始化在线网络  $Q_\theta$ 、目标网络  $Q_{\theta^-}$ 、经验回放缓冲区  $\mathcal{D}$ 
16: for  $t = 1$  to  $T$  do
17:   以  $\epsilon$ -贪心策略采样动作  $a_t$ , 执行并存储  $(s_t, a_t, r_t, s_{t+1})$  到  $\mathcal{D}$ 
18:   从  $\mathcal{D}$  采样长度为 8 的序列, 计算 Double DQN 目标
19:   反向传播更新  $\theta$ , 对 NCP 参数执行  $w, c_m, g_{leak} \geq 0$  裁剪
20:   线性衰减  $\epsilon$ ; 每 500 步更新  $\theta^- \leftarrow \theta$ 
21: end for
22: 返回 训练后的  $Q_\theta$  与  $g^*$ 

```

该框架的设计理念是**分层解耦**：NCP 负责时序动力学建模（液态 ODE），Q-head 负责值函数逼近（标准 MLP），训练算法负责稳定优化（Double DQN），搜索算法负责结构优化（进化策略）。各模块各司其职，可独立替换和分析。

3.2 神经电路策略 Q 网络设计

将 NCP 直接用作强化学习的 Q 网络时，面临一个关键设计问题：NCP 的运动层神经元数量等于动作维度（本文为 5），其输出值是否可以直接作为 Q 值？

在初步实验中，我们发现直接使用运动层输出作为 Q 值时，NCP 的性能接近随机策略。分析表明，LTC 的 ODE 动力学对参数施加了严格约束——突触权重和膜电容必须非负，反转电位固定为 ± 1 ，加上邻接矩阵 88.6% 的稀疏率，运动层仅有的 5 个神经元难以在如此受限的参数空间中表达复杂的 Q 值函数。

图 3.2 展示了 Q-head 解耦设计的整体架构。为解决这一问题，本文提出 **Q-head 解耦方案**：不使用 NCP 的运动层输出，而是将全部神经元的隐状态（中间层 + 命令层 + 运动层，共 $n_i + n_c + 5$ 维）送入一个独立的两层 MLP 进行 Q 值映射：

$$Q(s, a) = W_2 \cdot \text{ReLU}(W_1 \cdot h + b_1) + b_2 \quad (3.1)$$

其中 h 为 NCP 全部神经元的隐状态向量， $W_1 \in R^{32 \times (n_i + n_c + 5)}$ ， $W_2 \in R^{5 \times 32}$ 。该 Q-head 仅增加约 1,900 个参数（NCP 默认配置下），但显著提升了 Q 值的表达能力。




图 3.2 NCP Q 网络的 Q-head 解耦设计

这种解耦设计的核心思想是：让 NCP 的 ODE 动力学专注于**时序特征建模**——通过液态时间常数捕捉驾驶场景的动态变化；让 Q-head 专注于**值函数逼近**——将 NCP 提取

的动态特征映射为动作价值。两者分工明确，NCP 的可解释性（稀疏结构、兴奋/抑制极性）得以完整保留，同时 Q 值估计不再受 ODE 约束的限制。

在训练过程中，NCP 参数需要在每次梯度更新后执行权重裁剪 ($w, c_m, g_{leak} \geq 0$)，而 Q-head 参数不受此约束，两部分的梯度通过反向传播联合优化。

3.3 安全感知的布线拓扑搜索

NCP 的布线拓扑由 6 个离散参数决定（见 2.2 节），参数间存在不等式约束。为了自发现优于手工设计的布线方案，本文设计了一套基于进化策略的搜索框架。

3.3.1 搜索空间与约束

搜索空间定义为 6 维整数向量 $g = (n_i, n_c, f_s, f_i, r_c, f_m)$ ，各分量的取值范围为： $n_i \in [2, 20]$ ， $n_c \in [2, 16]$ ， $f_s \in [1, 8]$ ， $f_i \in [1, 8]$ ， $r_c \in [0, 8]$ ， $f_m \in [1, 8]$ 。约束条件为 $f_s \leq n_i$ ， $f_i \leq n_c$ ， $f_m \leq n_c$ 。违反约束的基因组在每次遗传操作后通过裁剪修复。

3.3.2 安全感知适应度函数

与仅优化奖励的传统方法不同，本文设计了安全感知的多目标适应度函数：

$$F(g) = \bar{R}(g) - \alpha \cdot \bar{C}(g) \quad (3.2)$$

其中 $\bar{R}(g)$ 和 $\bar{C}(g)$ 分别为候选布线 g 在训练后的平均累计奖励和平均碰撞率， $\alpha = 10$ 为安全惩罚系数。该设计使搜索不仅追求高奖励，还主动降低碰撞率，直接回应自动驾驶的安全性需求。

3.3.3 搜索流程

具体搜索参数为：种群大小 16，迭代 15 代，锦标赛大小 3，精英保留 2 个，交叉率 0.5，变异率 0.3。每个候选个体在 highway-v0 环境上快速训练 8,000 步后评估适应度。搜索过程中，一代内的所有个体在多 GPU 上并行评估，每代耗时约 30 分钟。

3.3.4 搜索结果

经过 15 代 240 次评估，搜索发现的最优布线为 $g^* = (3, 7, 3, 5, 0, 2)$ ，即仅需 3 个中间神经元、7 个命令神经元（共 15 个神经元，含 5 个运动神经元），远少于手工设计的 25 个。一个值得注意的发现是 $r_c = 0$ ，即最优拓扑**不需要命令层内的循环连接**。这表明在 highway-v0 的决策时间尺度上，LTC 的 ODE 动力学本身已提供了足够的短时记忆能力，额外的循环连接反而增加了不必要的复杂度。

搜索出的拓扑在 highway-v0 上取得了与手工设计相近的奖励（33.88 对 34.94），但在未参与搜索的 merge-v0 和 roundabout-v0 上性能有所下降（11.12 对 15.00 和 5.47 对 6.63），说明单环境搜索的拓扑存在过拟合风险，未来可通过多环境联合搜索改善泛化能力。

4 实验与分析

4.1 实验设置

4.1.1 仿真环境

本文使用 Highway-env^[12] 作为实验平台, 选取 4 个难度递进的驾驶场景: 高速公路巡航 (highway-v0, 40 秒)、匝道合流 (merge-v0, 约 40 秒)、无保护交叉路口 (intersection-v0, 13 秒)、环岛通行 (roundabout-v0, 11 秒)。所有场景统一配置为 5 个离散元动作 (左变道、保持、右变道、加速、减速), 仿真频率 5Hz。

4.1.2 观测空间

所有环境使用相同的运动学观测: 每辆车 7 个特征 (存在标志、相对位置 x/y 、相对速度 v_x/v_y 、朝向 $\cosh/\sinh$), 观测 5 辆车 (自车 + 最近 4 辆), 归一化后展平为 35 维向量。碰撞奖励设为 -5 以强化安全约束。

4.1.3 对比模型

实验对比 6 种模型: (1) 随机策略, 作为性能下界; (2) MLP (13,189 参数), 两层全连接网络; (3) LSTM (26,181 参数), 单层 64 维; (4) GRU (19,717 参数), 单层 64 维; (5) 全连接 LTC (7,152 参数), 与 NCP 参数量相同但采用全连接布线; (6) NCP (7,152 参数), 本文方法。所有模型使用相同的 Double DQN 训练配置。

4.1.4 训练配置

学习率 3×10^{-4} (Adam 优化器), 折扣因子 $\gamma = 0.99$, 批量大小 64, 经验回放容量 50,000, 目标网络每 500 步硬更新, ϵ 从 1.0 线性衰减至 0.05 (10,000 步内), 总训练 50,000 步, 梯度裁剪阈值 10.0。循环模型使用长度 8 的序列采样。每组实验使用 3 个随机种子 (0、42、123) 确保统计显著性。全部实验在两张 NVIDIA A10 GPU 上并行执行, 72 组基线实验约 2 小时完成。

4.2 基线对比实验

表 4.1 和表 4.2 分别展示了 6 种模型在 4 个驾驶场景上的平均奖励和碰撞率 (3 个种子的均值 $\pm$ 标准差)。

表 4.1 各模型在 4 个场景上的平均奖励 (3 个种子均值 $\pm$ 标准差)

模型	参数量	highway-v0	merge-v0	intersection-v0	roundabout-v0
Random	1	9.49 ± 2.21	7.47 ± 0.60	2.50 ± 0.89	4.46 ± 1.71
LSTM	26,181	24.62 ± 7.15	12.62 ± 1.27	3.55 ± 0.05	6.37 ± 0.76
FC-LTC	7,152	28.41 ± 1.10	13.53 ± 1.77	3.40 ± 0.30	6.32 ± 1.37
GRU	19,717	32.15 ± 3.36	14.45 ± 1.11	3.80 ± 0.44	6.28 ± 2.01
MLP	13,189	34.88 ± 3.37	15.77 ± 0.10	3.40 ± 0.72	7.08 ± 1.35
NCP (本文)	7,152	34.94 ± 1.21	15.00 ± 0.71	2.82 ± 0.68	6.63 ± 1.38

表 4.2 各模型在 4 个场景上的碰撞率 (3 个种子均值 $\pm$ 标准差)

模型	参数量	highway-v0	merge-v0	intersection-v0	roundabout-v0
Random	1	98.0% $\pm$ 0.4%	83.3% $\pm$ 1.9%	31.6% $\pm$ 1.3%	51.1% $\pm$ 1.8%
LSTM	26,181	56.8% $\pm$ 7.2%	36.4% $\pm$ 5.6%	30.2% $\pm$ 0.5%	46.2% $\pm$ 1.2%
FC-LTC	7,152	40.5% $\pm$ 1.7%	21.2% $\pm$ 4.9%	30.5% $\pm$ 0.5%	47.0% $\pm$ 2.9%
GRU	19,717	41.0% $\pm$ 5.1%	21.2% $\pm$ 3.7%	30.7% $\pm$ 0.5%	48.6% $\pm$ 5.1%
MLP	13,189	30.9% $\pm$ 1.5%	20.2% $\pm$ 3.7%	30.7% $\pm$ 0.7%	43.9% $\pm$ 0.8%
NCP (本文)	7,152	37.9% $\pm$ 1.2%	21.2% $\pm$ 2.7%	30.5% $\pm$ 1.0%	50.8% $\pm$ 2.2%

图 4.1展示了 5 种学习模型在 4 个场景上的训练曲线 (3 个种子的均值 $\pm$ 标准差)。
可以观察到: NCP 在 highway-v0 上收敛速度与 MLP 相当, 但方差阴影更窄, 说明训练更稳定; LSTM 在所有场景上波动最大。

Training Curves (3 seeds, mean $\pm$ std)




图 4.1 5 种模型在 4 个驾驶场景上的训练曲线 (3 个种子均值 $\pm$ 标准差)

图 4.2和图 4.3分别以柱状图形式直观对比了各模型的最终奖励和碰撞率。

Final Reward Comparison (3 seeds, mean $\pm$ std)




图 4.2 各模型最终奖励对比 (3 个种子均值, 含误差棒)




图 4.3 各模型碰撞率对比（3 个种子均值，含误差棒）

4.2.1 主要发现

(1) **NCP 以更少参数取得领先奖励。**在 highway-v0 场景上，NCP 以 7,152 参数取得 34.94 的奖励，与拥有 13,189 参数的 MLP (34.88) 持平，且方差 (1.21) 显著低于 MLP (3.37)、GRU (3.36)、LSTM (7.15)，训练表现更稳定。其参数效率 (reward/千参数 = 4.89) 是 MLP (2.64) 的 1.9 倍，GRU (1.63) 的 3.0 倍，LSTM (0.94) 的 5.2 倍。

(2) **结构化稀疏拓扑优于全连接。**NCP 与 FC-LTC 参数量完全相同 (7,152)，唯一区别是连接拓扑。在 highway-v0 上，NCP 奖励比 FC-LTC 高 23% (34.94 对 28.41)，二者方差均处于较低水平 (NCP 1.21、FC-LTC 1.10)。这一结果定量证明了 NCP 的四层稀疏布线结构在表达能力上优于全连接设计，且并未以训练稳定性为代价。

(3) **困难场景下所有模型趋同。**在 intersection-v0 和 roundabout-v0 上，所有模型的表现差异不大 (intersection 碰撞率均约 30%，roundabout 约 45%–50%)，说明这两个场景的难度超出了当前训练配置的能力。

(4) **碰撞率方面 MLP 最优。**MLP 在 highway-v0 上碰撞率最低 (30.9%)，NCP 为 37.9%。这可能因为 MLP 的前馈结构能更快地响应碰撞信号，而 NCP 的 ODE 动力学引入了一定的响应延迟。这一不足可通过拓扑搜索（优化信息传播路径）或 ODE 展开数调

整来改善。

4.3 消融实验

4.3.1 布线拓扑搜索结果

经过 15 代进化搜索（种群 16，并行评估），搜索到的最优布线为：中间神经元 $n_i = 3$ ，命令神经元 $n_c = 7$ ，感觉扇出 $f_s = 3$ ，中间扇出 $f_i = 5$ ，命令循环连接 $r_c = 0$ ，运动扇入 $f_m = 2$ 。搜索出的拓扑共 15 个神经元，较手工设计的 25 个减少 40%。

表 4.3 手工设计与搜索出的 NCP 拓扑在 4 个场景上的对比

拓扑	神经元数	highway-v0	merge-v0	intersection-v0	roundabout-v0
手工设计	25	34.94 ± 1.21	15.00 ± 0.71	2.82 ± 0.68	6.63 ± 1.38
搜索发现	15	33.88 ± 1.50	11.12 ± 3.74	3.22 ± 0.41	5.47 ± 1.45

图 4.4 直观展示了两两种拓扑在各场景上的奖励和碰撞率对比。搜索出的拓扑在 highway-v0（搜索环境）上与手工设计接近（33.88 对 34.94），但在未参与搜索的 merge-v0 和 roundabout-v0 上性能下降。这说明单环境搜索存在过拟合风险，也从侧面证明了布线拓扑确实对 NCP 的性能有显著影响——不同的拓扑适合不同的场景特征。




图 4.4 手工设计拓扑与搜索拓扑在 4 个场景上的奖励和碰撞率对比

搜索收敛曲线（图 4.5）显示，最佳适应度在前 3 代快速上升，之后趋于稳定，说明进化搜索能有效探索布线空间。




图 4.5 进化搜索收敛曲线

4.3.2 搜索拓扑的结构分析

图 4.6展示了搜索出的最优拓扑。与第 2 章图 2.1的手工设计拓扑（25 个神经元）相比，搜索拓扑仅有 15 个神经元，连接更稀疏，且不含命令层内循环连接。




图 4.6 进化搜索发现的 NCP 最优布线拓扑 (15 个神经元)

搜索出的拓扑有两个值得关注的特征：(1) $r_c = 0$ ，即命令层内无循环连接。传统 NCP 设计认为循环连接对维持短时记忆至关重要，但搜索结果表明，在 highway-v0 的决策时间尺度上，LTC 的 ODE 动力学本身已提供足够的记忆能力。(2) $n_i = 3$ ，仅 3 个中间神经元，表明高速公路场景的信息整合不需要大量中间层冗余。这些发现为 NCP 的布线设计提供了数据驱动的指导。

4.3.3 ODE 展开数消融实验

LTC 单元中的 ODE 展开数 (ode_unfolds) 控制了每个 RNN 时间步内 Euler 积分的迭代次数，是 NCP 的关键超参数。展开数越多，ODE 求解越精确，但计算图也越深。本文在 highway-v0 上对 1、3、6、12 四种展开数进行了系统消融，结果如表 4.4 所示。

表 4.4 ODE 展开数对 NCP 性能的影响 (highway-v0, seed=42, 50000 步训练)

ODE 展开数	平均奖励	碰撞率	相对训练速度
1	34.53	41.9%	1.0× (最快)
3	35.97	37.2%	0.6×
6 (默认)	26.61	35.1%	0.4×
12	34.51	34.7%	0.2× (最慢)

实验得到三个观察：

(1) **展开数 3 取得最佳综合性能**。ode_unfolds=3 时 reward 达到 35.97 (4 个设置中最高)，同时碰撞率 37.2% 也较低。这表明对于离散决策任务，3 步 Euler 积分已能较好地近似 ODE 动力学。

(2) **默认展开数 6 在本次实验中表现波动较大**。ode_unfolds=6 (NCP 论文默认值) 在该单一种子实验中 reward 仅 26.61，明显低于其他三个设置。这可能源于该种子下的训练不稳定性，也可能反映了计算图深度对梯度传播的影响——对比基线对比实验 (4.2 节) 中 NCP 在 3 个种子上的均值为 34.94 ± 1.21 ，可见 ode=6 的实际表现存在较大波动。

(3) **极端展开数各有取舍**。ode_unfolds=1 训练速度最快 (约为默认值的 2.5 倍)，适合资源受限场景；ode_unfolds=12 碰撞率最低 (34.7%)，可能更适合对安全性要求极高的场景，但训练速度仅为默认值的一半。

局限性说明：本消融实验仅在单一种子上进行，结论的统计可靠性有限——尤其是 ode=6 的低 reward 可能受随机性影响较大。但 4 个设置之间的总体趋势 (reward 在 26–36 之间，方差较大) 仍提示：ODE 展开数对 NCP 的训练动力学有显著影响，简单沿用默认值 6 可能错失更优配置。在工程实践中，建议针对具体任务对此超参数进行调优，3 步展开是一个值得尝试的备选。

4.4 可解释性分析

为展示 NCP 相比黑箱模型的可解释性优势，本节从参数效率和结构可解释性两个维度进行分析。

4.4.1 参数效率分析

图 4.7展示了各模型在 highway-v0 上的参数量-性能帕累托前沿。NCP 位于左上角(少参数、高性能)，是帕累托最优点。具体而言，NCP 的参数效率 (reward/千参数) 为 4.89，是 MLP (2.64) 的 1.9 倍，GRU (1.63) 的 3.0 倍，LSTM (0.94) 的 5.2 倍。这说明 NCP 的生物启发稀疏结构能够以极高的参数利用率编码驾驶策略。




图 4.7 参数量与性能的帕累托前沿图 (highway-v0 场景)

4.4.2 命令神经元激活分析

图 4.8展示了一次 highway-v0 完整 episode 中 8 个命令神经元的激活值 (热图)，以及同步的 Q 值曲线、动作序列和奖励。可以观察到：(1) 不同命令神经元呈现明显不同

的激活模式——Cmd 3 和 Cmd 7 持续高激活（深红），Cmd 4 为强负激活（深蓝），说明各神经元承担了差异化的功能角色；（2）在动作切换时刻（如第 5-7 步从 IDLE 切换到 SLOWER 再到 RIGHT），命令层激活发生同步跃变，表明命令层确实编码了决策信号。




图 4.8 highway-v0 场景中命令神经元激活、Q 值、动作和奖励的时序对齐图

4.4.3 神经元功能归因

为定量分析每个命令神经元对各动作的影响，本文采用逐神经元 mask 实验：依次将每个命令神经元的激活置零，测量 Q 值的变化量 $|\Delta Q|$ 。图 4.9 展示了归因矩阵。

Cmd 7 对所有动作影响最大 ($|\Delta Q|$ 达 2.96–3.17)，是最关键的全局决策神经元；Cmd 1 影响最小（约 1.0），可能是冗余神经元。值得注意的是，Cmd 0 对 LEFT 动作的影响 (2.40) 明显高于对 RIGHT 的影响 (2.07)，暗示该神经元编码了方向选择性信息。




图 4.9 命令神经元功能归因矩阵（逐神经元 mask 后 Q 值变化量）

4.4.4 跨场景激活模式对比

图 4.10展示了 4 个驾驶场景下命令层激活的 PCA 降维结果。前两个主成了解释了 84.6% 的方差（PC1: 47.6%, PC2: 37.0%）。Highway 场景的激活点分布最广（episode 最长），Intersection 和 Roundabout 的点较分散（场景复杂度高），且 4 个场景在 PCA 空间中存在部分重叠——这说明 NCP 学到了一些场景无关的通用决策模式（如减速避障），同时也能区分不同场景的特有状态。




图 4.10 4 个驾驶场景下命令神经元激活的 PCA 降维可视化

4.4.5 结构可解释性讨论

NCP 的可解释性优势源于其结构化设计，具体体现在三个层面：

层次化功能分工。四层布线使感觉层、中间层、命令层、运动层各司其职。感觉层编码环境特征，中间层整合信息，命令层做出决策，运动层输出控制——信息流路径可被完整追踪。对比之下，MLP 和 LSTM 的全连接结构中，任何一个隐藏单元都可能同时参与编码、整合和决策，难以分辨各单元的功能角色。

兴奋/抑制极性。NCP 的每条突触具有明确的兴奋性 (+1) 或抑制性 (-1) 标签，提供了因果推理线索。例如，一条从命令层到运动层的抑制性连接可以被解读为“该命令神经元抑制了某个动作的选择”。这种内置的因果结构是传统神经网络所不具备的。

可审计的规模。默认 NCP 仅 25 个神经元，搜索出的拓扑更是只有 15 个。这使得对网络进行逐神经元审计成为可能——人类可以检查每个神经元在特定决策中的角色。相

比之下，LSTM 的 64 维隐藏状态和 MLP 的 128 维中间层远超人类直接理解的能力。

以上三个层面的可解释性是 NCP 的内在属性，无需额外的事后解释方法（如 Grad-CAM），且在拓扑搜索后仍然保持——搜索出的 15 神经元拓扑同样具备完整的层次分工和极性标注。这为自动驾驶系统满足欧盟 AI 法案的透明性要求^[5] 提供了结构性支撑。

5 结论与展望

5.1 结论

本文围绕“可解释自动驾驶规划”这一主题，提出了基于神经电路策略（NCP）的轻量可解释规划方法，并通过进化搜索自动优化其布线拓扑。主要贡献和结论如下：

(1) 发现并解决了 NCP 在强化学习 Q 值估计中的表达能力瓶颈。通过将 NCP 全部神经元隐状态经两层 MLP 映射为 Q 值（Q-head 解耦方案），在保持液态 ODE 动力学可解释性的同时，将性能从接近随机策略提升至与最优基线持平。

(2) NCP 以 7,152 个参数在高速公路场景上取得了 34.94 的平均奖励，与拥有 13,189 参数的 MLP（34.88）相当，参数效率是 GRU 的 3 倍、LSTM 的 5 倍。与同参数量的全连接 LTC 相比，NCP 的结构化稀疏拓扑使奖励提升 23%，定量证明了生物启发布线结构的优势。

(3) 设计了面向 NCP 布线拓扑的安全感知进化搜索算法，发现最优拓扑仅需 15 个神经元（较手工设计减少 40%），且命令层无需循环连接。搜索结果表明 NCP 的 ODE 动力学本身已具备足够的短时记忆能力。

(4) NCP 的四层结构化设计赋予了每层神经元明确的功能角色，使决策过程可被逐层追踪和审计，为自动驾驶系统的安全合规提供了结构性支撑。

5.2 展望

本文的工作存在以下不足和改进方向：

(1) 搜索仅在单一环境上评估适应度，导致搜索出的拓扑在其他场景上泛化不足。未

来可采用多环境联合搜索或元学习策略改善跨场景泛化能力。

(2) 当前实验平台为轻量级的 Highway-env 仿真器, 场景复杂度有限。未来可在 CARLA 或 nuPlan 等高保真仿真器上验证, 或在真实驾驶数据上进行评估。

(3) 本文已通过逐神经元 mask 归因和 PCA 激活聚类等手段开展了定量可解释性分析, 但仍以单步 Q 值变化和无监督降维为主。未来可进一步引入反事实归因、因果中介分析以及碰撞前关键时刻的异常激活检测, 建立更严格、更贴近安全合规需求的可解释性评价体系。

(4) NCP 的碰撞率仍高于 MLP, 可进一步探索安全奖励塑形、约束强化学习、或将 NCP 与安全过滤器结合的方案来改善安全性。

(5) ODE 展开数消融实验 (4.3.3 节) 揭示了默认超参数并非最优, 但受限于时间仅在单一种子上完成, 未来应在多种子上系统调优 ode_unfolds 参数, 并探索其与训练稳定性、梯度传播之间的深层关系。初步结果表明 3 步展开是一个值得深入研究的候选配置。

(6) 可探索将闭式连续时间网络 (CfC) 替代 LTC 作为 NCP 的基础单元, 消除 ODE 求解器的计算开销, 同时保留液态动力学的自适应特性。

参考文献

- [1] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Planning-oriented autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17853–17862, 2023.
- [2] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. VAD: Vectorized scene representation for efficient autonomous driving. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 8340–8350, 2023.
- [3] Xiaosong Jia, Junqi You, Zhiyuan Zhang, and Junchi Yan. DriveTransformer: Unified transformer for scalable end-to-end autonomous driving. In *International Conference on Learning Representations*, 2025.
- [4] Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A multimodal dataset for autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11621–11631, 2020.
- [5] European Parliament and Council of the European Union. Regulation (EU) 2024/1689 of the European Parliament and of the Council laying down harmonised rules on artifi-

- cial intelligence (artificial intelligence act). Official Journal of the European Union, OJ L, 2024/1689, 12 July 2024. <http://data.europa.eu/eli/reg/2024/1689/oj>, 2024.
- [6] Eloi Zablocki, Hedi Ben-Younes, Patrick Pérez, and Matthieu Cord. Explainability of deep vision-based autonomous driving systems: Review and challenges. *International Journal of Computer Vision*, 130(10):2425–2452, 2022.
- [7] Mathias Lechner, Ramin Hasani, Alexander Amini, Thomas A Henzinger, Daniela Rus, and Radu Grosu. Neural circuit policies enabling auditable autonomy. *Nature Machine Intelligence*, 2(10):642–652, 2020.
- [8] John G White, Eileen Southgate, J Nichol Thomson, and Sydney Brenner. The structure of the nervous system of the nematode *Caenorhabditis elegans*. *Philosophical Transactions of the Royal Society of London. B, Biological Sciences*, 314(1165):1–340, 1986.
- [9] Ramin Hasani, Mathias Lechner, Alexander Amini, Lucas Liebenwein, Aaron Ray, Max Tschaikowski, Gerald Teschl, and Daniela Rus. Closed-form continuous-time neural networks. *Nature Machine Intelligence*, 4(11):992–1003, 2022.
- [10] Ramin Hasani, Mathias Lechner, Tsun-Hsuan Wang, Makram Chahine, Alexander Amini, and Daniela Rus. Liquid structural state-space models. In *International Conference on Learning Representations*, 2023.
- [11] Liquid AI Team. LFM2 technical report. *arXiv preprint arXiv:2511.23404*, 2025.
- [12] Edouard Leurent. An environment for autonomous driving decision-making. <https://github.com/eleurent/highway-env>, 2018.

- [13] Wenchao Sun, Xuewu Lin, Yining Shi, Chuang Zhang, Haoran Wu, and Sifa Zheng. SparseDrive: End-to-end autonomous driving via sparse scene representation. *arXiv preprint arXiv:2405.19620*, 2024.
- [14] Jyh-Jing Hwang, Runsheng Xu, Hubert Lin, Wei-Chih Hung, Jingwei Ji, Kristy Choi, Di Huang, Tong He, et al. EMMA: End-to-end multimodal model for autonomous driving. *arXiv preprint arXiv:2410.23262*, 2024.
- [15] Xiaoyu Tian, Junru Gu, Bailin Li, Yicheng Liu, Yang Wang, Zhiyong Zhao, Kun Zhan, Peng Jia, Xianpeng Lang, and Hang Zhao. DriveVLM: The convergence of autonomous driving and large vision-language models. *arXiv preprint arXiv:2402.12289*, 2024.
- [16] Bencheng Liao, Shaoyu Chen, Haoran Yin, Bo Jiang, Cheng Wang, Sixu Yan, Xinbang Zhang, Xiangyu Li, Ying Zhang, Qian Zhang, and Xinggang Wang. DiffusionDrive: Truncated diffusion model for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [17] Bernhard Jaeger, Daniel Dauner, Jens Beißwenger, Simon Gerstenecker, Kashyap Chitta, and Andreas Geiger. CaRL: Learning scalable planning policies with simple rewards. In *Conference on Robot Learning*, 2025.
- [18] Ramin Hasani, Mathias Lechner, Alexander Amini, Daniela Rus, and Radu Grosu. Liquid time-constant networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pages 7657–7666, 2021.
- [19] Makram Chahine, Ramin Hasani, Patrick Kao, Aaron Ray, Ryan P Adams, and Daniela

- Rus. Robust flight navigation out of distribution with liquid neural networks. *Science Robotics*, 8(77):eadc8892, 2023.
- [20] Kenneth O Stanley and Risto Miikkulainen. Evolving neural networks through augmenting topologies. *Evolutionary computation*, 10(2):99–127, 2002.
- [21] Hanxiao Liu, Karen Simonyan, and Yiming Yang. DARTS: Differentiable architecture search. In *International Conference on Learning Representations*, 2019.
- [22] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- [23] Hado Van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1), 2016.
- [24] Xiaosong Jia, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang, and Junchi Yan. Bench2Drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. In *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, 2024.
- [25] Shahin Atakishiyev, Mohammad Salameh, Hengshuai Yao, and Randy Goebel. Explainable artificial intelligence for autonomous driving: A comprehensive overview and field guide for future research directions. *arXiv preprint arXiv:2112.11561*, 2024.

致 谢

本课程结课大作业的完成，离不开各位老师和同学的帮助与支持，在此表示衷心的感谢。

首先，感谢卢炳先老师一学期来的悉心教导。卢老师在课堂上深入浅出地讲解了机器学习的核心理论与前沿方法，从监督学习、无监督学习到深度学习、强化学习，构建了完整的知识体系。这些系统化的知识为本大作业的选题和实施奠定了坚实基础。特别感谢卢老师在课程中对神经网络架构、可解释性等主题的讲解，直接启发了本文“基于神经回路策略的可解释自动驾驶规划”这一研究方向的形成。

其次，感谢课程中一起学习讨论的同学们。在课后讨论与实验交流中，同学们提出的问题和建议让我从多个角度重新审视本文的方法设计，改进了许多细节。

感谢神经电路策略（NCP）和液态时间常数网络（LTC）原作者 Lechner、Hasani 等人开源的高质量代码库，以及 Highway-env 仿真平台的贡献者们，为本大作业的实验工作提供了便利。

由于时间和能力有限，本大作业仍存在一些不足之处——例如消融实验的种子数量较少、搜索环境的覆盖不够全面等。恳请卢老师批评指正。

孙家恒

二〇二六年五月

附录

附录 A：实验超参数详细配置

表 5.5 实验超参数汇总

类别	参数	值
DQN 训练	学习率	3×10^{-4}
	折扣因子 γ	0.99
	批量大小	64
	经验回放容量	50,000
	目标网络更新频率	每 500 步
	梯度裁剪阈值	10.0
ϵ -贪心	初始值	1.0
	终止值	0.05
	衰减步数	10,000
循环模型	序列长度	8
	隐藏状态初始化	零向量
NCP 默认布线	中间神经元数 n_i	12
	命令神经元数 n_c	8
	感觉扇出 f_s	4
	中间扇出 f_i	4
	命令循环连接数 r_c	4
	运动扇入 f_m	4
进化搜索	种群大小	16
	代数	15
	锦标赛大小	3
	精英保留数	2
	交叉率	0.5
	变异率	0.3
	适应度训练步数	8,000
训练规模	基线训练步数	50,000
	种子数	3 (0, 42, 123)
	评估 episode 数	50

附录 B：NCP 布线搜索空间

表 5.6 进化搜索的 6 个基因及取值范围

基因	含义	取值范围	搜索结果
n_i	中间神经元数	[2, 20]	3
n_c	命令神经元数	[2, 16]	7
f_s	感觉扇出	[1, 8]	3
f_i	中间扇出	[1, 8]	5
r_c	命令循环连接数	[0, 8]	0
f_m	运动扇入	[1, 8]	2

约束条件： $f_s \leq n_i$, $f_i \leq n_c$, $f_m \leq n_c$ 。违反约束的基因组在每次遗传操作后通过裁剪修复。

附录 C：核心代码结构

表 5.7 代码模块结构

模块	功能
envs/env_factory.py	Highway-env 环境统一封装
models/wiring.py	NCP 布线类 (Wiring, NCP, FullyConnected)
models/ltc_cell.py	LTC 单元 PyTorch 实现
models/q_networks.py	6 种 Q 网络 (Random, MLP, LSTM, GRU, NCP, FC_LTC)
models/dqn_agent.py	Double DQN 智能体
utils/replay_buffer.py	经验回放缓冲区 (支持序列采样)
search/genome.py	布线基因组 (变异、交叉、约束修复)
search/evolution.py	进化搜索主循环 (并行评估)
scripts/train.py	单模型训练入口
scripts/run_search.py	进化搜索入口
scripts/run_ablation_ode.py	ODE 展开数消融
scripts/plot_results.py	结果可视化

本研究的完整代码、实验日志和模型权重已整理到项目仓库，包含超过 2,000 行 Python 代码和完整的实验复现脚本。