学号 20235937　　密级_____

东北大学本科毕业论文

面向可解释自动驾驶规划的神经回路策略拓扑优化

学院名称　：计算机科学与工程学院

专业名称　：计算机科学与技术

学生姓名　：孙家恒

指导教师　：卢炳先副教授

二〇二六年五月

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：_____　　日期：_____

摘要

自动驾驶规划系统面临计算效率、可解释性合规和长尾泛化三大挑战。当前端到端大模型参数量巨大、不可解释，难以满足边缘部署和安全认证需求。神经电路策略（NCP）以极少参数和生物启发的稀疏结构提供了一条差异化路径，但其布线拓扑完全依赖手工设计，且在强化学习场景下的适用性尚未得到验证。

本文提出一种基于 NCP 的可解释自动驾驶规划方法。首先，将 NCP 集成为 Double DQN 的 Q-network，针对 NCP 的 ODE 约束导致的表达能力瓶颈，提出两层 Q-head 方案，在保持液态动力学可解释性的同时实现有效的 Q 值估计。其次，设计面向 NCP 布线拓扑的进化搜索算法，采用安全感知的多目标适应度函数，自动发现兼顾性能与安全性的最优布线方案。

在 Highway-env 的 4 个驾驶场景上，与 MLP、LSTM、GRU、全连接 LTC 等 5 种基线模型进行了系统对比实验。结果表明，NCP 以 7,152 个参数在高速公路场景上取得了与 13,189 参数的 MLP 相当的奖励（34.94 对 34.88），参数效率是 GRU 的 3 倍以上，且方差最低（1.21）。与同参数量的全连接 LTC 相比，NCP 的结构化稀疏拓扑在奖励上提升了 23%。多层次可解释性分析揭示了 NCP 命令层神经元与驾驶决策之间的对应关系。

关键词: 神经电路策略；液态时间常数网络；自动驾驶规划；拓扑搜索；可解释人工智能

ABSTRACT

Autonomous driving planning systems face three major challenges: computational efficiency, interpretability compliance, and long-tail generalization. Current end-to-end large models are parameter-heavy and opaque, making them unsuitable for edge deployment and safety certification. Neural Circuit Policies (NCP), with their minimal parameters and biologically-inspired sparse structure, offer a differentiated approach, but their wiring topology relies entirely on manual design, and their applicability in reinforcement learning scenarios remains unverified.

This thesis proposes an interpretable autonomous driving planning method based on NCP. First, NCP is integrated as the Q-network of Double DQN. To address the expressivity bottleneck caused by NCP's ODE constraints, a two-layer Q-head scheme is proposed, enabling effective Q-value estimation while preserving the interpretability of liquid dynamics. Second, an evolutionary search algorithm for NCP wiring topology is designed with a safety-aware multi-objective fitness function, automatically discovering optimal wiring configurations that balance performance and safety.

Systematic experiments are conducted on four driving scenarios in Highway-env, comparing against five baseline models including MLP, LSTM, GRU, and fully-connected LTC. Results show that NCP achieves comparable reward to MLP (34.94 vs 34.88) on the highway scenario with only 7,152 parameters (vs 13,189), achieving over 3x the parameter efficiency of GRU with the lowest variance (1.21). Compared with fully-connected LTC at the same parameter count, NCP's structured sparse topology improves reward by 23%. Multi-level interpretability analysis reveals the correspondence between NCP command neurons and driving decisions.

Key words: Neural Circuit Policies; Liquid Time-Constant Networks; Autonomous Driving Planning; Topology Search; Explainable Artificial Intelligence

目 录

1 绪论 1
1.1 课题背景及目的 1
1.2 国内外研究状况 2
1.2.1 国外研究现状 2
1.2.2 国内研究现状 3
1.3 本文的研究内容和技术路线 3
1.4 本章小结 4
2 相关技术 5
2.1 液态时间常数网络 5
2.2 神经电路策略 5
2.3 深度 Q 网络与 Double DQN 6
2.4 进化搜索算法 7
3 基于神经电路策略的可解释规划方法 8
3.1 整体框架 8
3.2 神经电路策略 Q 网络设计 8
3.3 安全感知的布线拓扑搜索 8
4 实验与分析 9
4.1 实验设置 9
4.2 基线对比实验 9
4.3 消融实验 9
4.4 可解释性分析 9
5 结论与展望 10
参考文献 13
致谢 14

附录 15

1 绪论

1.1 课题背景及目的

自动驾驶规划系统负责根据感知信息生成安全、高效的驾驶轨迹，是自动驾驶技术栈中的核心环节。近年来，该领域经历了从传统模块化流水线向端到端学习的范式转变。UniAD[1]、VAD[2]、DriveTransformer[3] 等端到端 Transformer 模型在 nuScenes[4] 等基准上取得了领先性能，推动了感知-预测-规划的联合优化。

然而，当前自动驾驶规划仍面临三大核心挑战。其一，**计算效率**问题：端到端大模型参数量巨大，难以在车端边缘设备上实时部署，而 L2 级自动驾驶系统要求端到端延迟在 20–100ms 之内。其二，**可解释性与安全合规**问题：欧盟《人工智能法案》将于 2026 年 8 月全面执行[5]，自动驾驶系统被归类为高风险 AI 系统，要求具备可追溯性和可解释性；当前端到端黑箱模型无法满足这一合规要求[6]。其三，**长尾场景泛化**问题：模型在分布外罕见场景下表现不稳定，难以保证安全性。

与此同时，生物启发的液态神经网络展示了独特潜力。Lechner、Hasani 等人[7] 提出的神经电路策略（Neural Circuit Policies, NCP）受秀丽隐杆线虫神经连接组[8] 启发，仅用 19 个神经元和 253 个突触即可完成自动驾驶车道保持任务，参数量比传统 LSTM 网络少数个数量级，且注意力自动聚焦道路关键区域，具备内在可解释性。后续工作包括闭式连续时间网络 CfC[9]（将推理速度提升 5–8 倍）和 Liquid-S4[10]（实现并行训练），最终演化为 Liquid AI 公司的 LFM 系列大模型[11]。

然而，NCP 的四层布线拓扑（感觉层 → 中间层 → 命令层 → 运动层）目前完全依赖手工设计，缺乏系统化的优化方法。此外，NCP 在强化学习场景下的适用性尚未得到充分验证——其 ODE 动力学约束（权重非负、稀疏连接、固定极性）是否与 Q-value 估计兼容，是一个未被探索的问题。

基于上述背景，本文提出将 NCP 作为自动驾驶规划的轻量可解释 Planning Head，设计进化搜索算法自动优化其布线拓扑，并在 Highway-env[12] 仿真平台上进行系统验证。本研究旨在回答以下问题：（1）NCP 能否以极少参数量达到甚至超越传统 MLP/LSTM/GRU 的

决策性能?（2）能否通过自动化搜索发现比手工设计更优的 NCP 布线拓扑?（3）NCP 的结构化稀疏连接是否带来可量化的性能和安全性优势?

1.2 国内外研究状况

1.2.1 国外研究现状

端到端自动驾驶规划方面,UniAD[1](CVPR 2023 最佳论文)首次将检测、跟踪、建图、运动预测和规划统一在 Transformer 框架中，在 nuScenes 规划基准上取得 L2 误差 0.71m。VAD[2] 用向量化场景表示替代稠密栅格，显著降低计算开销。SparseDrive[13] 采用全稀疏架构实现感知-规划端到端。DriveTransformer[3]（ICLR 2025）提出任务间双向交互的 Transformer 架构，成为端到端规划的最新代表。2025 年，稀疏表示与端到端联合优化已成为主流范式。

大模型驱动的规划方面，EMMA[14]（Waymo，基于 Gemini）将端到端驾驶统一为视觉-语言生成任务。DriveVLM[15] 结合视觉语言模型的链式推理与传统规划器，实现双系统架构。扩散模型规划方面，DiffusionDrive[16]（CVPR 2025）通过截断扩散实现高效多模态轨迹生成。强化学习方面，CaRL[17] 采用大规模 PPO 训练超越了此前所有方法。然而，上述方法均面临推理延迟高、参数量大、可解释性不足等共同挑战。

液态神经网络方面，Hasani 等人[18] 提出的液态时间常数网络（LTC）通过输入自适应的 ODE 动力学实现高效时序建模。NCP[7] 将 LTC 与生物启发的四层稀疏布线结合，以极少参数实现车道保持。CfC[9] 用闭式解替代 ODE 求解器，将推理速度提升 5–8 倍。Chahine 等人[19] 在 *Science Robotics* 上展示了仅 19 个神经元的 NCP 在分布外飞行导航中远超大型网络的鲁棒性。Liquid AI 在 2025 年发布了 LFM2 系列模型[11]，完成了从 ODE 动力学到门控短卷积 +GQA 混合架构的演进。

神经架构搜索方面，NEAT[20] 专门针对网络拓扑的进化搜索，DARTS[21] 将搜索时间从数千 GPU 天降至数天。然而，面向 NCP 布线拓扑的自动化搜索尚属空白。

深度强化学习方面，DQN[22] 通过经验回放和目标网络稳定训练，是离散动作空间的经典方法。Double DQN[23] 通过解耦动作选择和 Q-value 评估减少过估计。Highway-env[12] 提供了高速公路、匝道合流、交叉路口、环岛等多种驾驶场景，是 RL 驾驶研究的标准平台。

1.2.2 国内研究现状

国内在自动驾驶规划领域发展迅速。清华大学 MARS 实验室提出 DriveVLM[15]，将视觉语言模型的链式推理能力引入驾驶规划。上海交通大学 Thinklab 团队构建了 Bench2Drive[24] 闭环评测基准，包含 44 种交互场景和 220 条评测路线，推动了端到端方法的公平比较。

在产业应用方面，理想汽车已在量产车上部署视觉-语言-动作（VLA）架构；小鹏汽车的图灵芯片支持 VLA 与自主强化学习模型的运行。中国工信部于 2024 年发布《智能网联汽车准入管理》规定，要求 L3 及以上自动驾驶系统具备决策可追溯能力，这与欧盟 AI 法案的要求形成呼应，进一步推动了可解释自动驾驶的研究需求。

在可解释性研究方面，Atakishiyev 等人[25] 系统总结了可解释 AI 在自动驾驶领域的五类贡献；Zablocki 等人[6] 在 IJCV 综述中指出，黑箱模型缺乏因果理解能力是获取监管信任的核心障碍。国内外学者普遍认为，**内在可解释架构**（如 NCP 的结构化稀疏设计）比事后解释方法（如 Grad-CAM）更适合高风险的自动驾驶场景。

综合来看，当前自动驾驶规划领域存在” 性能-效率-可解释性” 三角困境：高性能模型参数量大、不可解释；轻量模型性能不足；可解释方法多为事后分析，无法提供结构性保证。NCP 以其极少参数、内在可解释性和生物启发的稀疏结构，为打破这一困境提供了可能。

1.3 本文的研究内容和技术路线

本文以神经电路策略（NCP）为核心，围绕” 可解释自动驾驶规划” 展开研究，主要内容包括以下四个部分：

（1）NCP 规划头的性能验证。将 NCP 集成为 Double DQN 的 Q-network，针对 NCP 的 ODE 约束问题提出两层 Q-head 方案（用全部神经元隐状态经 MLP 映射 Q-values），在 Highway-env 的 4 个场景（高速巡航、匝道合流、交叉路口、环岛）上与 Random、MLP、LSTM、GRU、全连接 LTC 共 6 种模型进行系统对比。采用 3 个随机种子确保统计显著性，评估维度包括累计奖励、碰撞率、参数量、推理延迟和参数效率。

（2）NCP 布线拓扑的进化搜索。设计结构化搜索空间（6 个离散基因：神经元数量、扇出/扇入度、循环连接数），使用进化策略（锦标赛选择 + 均匀交叉 + 高斯变异）进行搜索。采用安全感知的多目标适应度函数，在多场景联合评估下自动发现兼顾性能与安全性的最

优布线方案。

（3）消融实验。包括三组消融：Q-head 消融（验证两层 Q-head 对 NCP 性能的必要性）、ODE 展开数消融（确定精度-效率最优权衡点）、网络规模消融（探究 NCP 性能与规模的关系）。

（4）多层次可解释性分析。设计涵盖 5 个层次的分析框架：结构层（拓扑统计量对比）、动态层（command 神经元激活与驾驶决策对齐）、安全层（碰撞前关键时刻异常激活识别）、因果层（逐神经元 mask 的功能归因矩阵）、泛化层（跨场景激活降维对比）。

本文的技术路线为：首先在 Highway-env 上搭建统一的实验框架，验证 NCP 的基线性能；然后通过进化搜索优化布线拓扑；接着通过消融实验分析各设计要素的贡献；最后通过多层次可解释性分析展示 NCP 的独特价值。

本文的预期结果包括：（1）NCP 以不到 1 万参数达到与 LSTM、GRU 等传统循环网络相当甚至更优的决策性能，验证其作为轻量规划头的可行性；（2）进化搜索发现的最优布线拓扑在累计奖励和碰撞率上优于手工设计的默认拓扑；（3）消融实验定量揭示两层 Q-head、ODE 展开数和网络规模对 NCP 性能的贡献程度；（4）多层次可解释性分析表明 NCP 的结构化稀疏连接能够产生与驾驶语义对齐的神经元激活模式，为自动驾驶规划系统的安全合规提供结构性支撑。

1.4 本章小结

本章首先阐述了自动驾驶规划领域的三大核心挑战——计算效率、可解释性合规和长尾泛化，指出了当前端到端大模型在边缘部署和安全认证方面的不足。随后，系统梳理了国内外在端到端规划、大模型驱动规划、扩散模型规划、液态神经网络、神经架构搜索和深度强化学习等方向的研究进展。

通过文献调研发现：（1）NCP 以极少参数实现了可解释的自动驾驶控制，但其布线拓扑完全依赖手工设计；（2）NCP 在强化学习 Q-value 估计场景下的适用性尚未被探索；（3）NCP 的结构化稀疏连接相比全连接 LTC 的优势缺乏定量验证。这些研究空白构成了本文的出发点。

2 相关技术

2.1 液态时间常数网络

液态时间常数网络（Liquid Time-Constant Networks, LTC）[18] 是一种基于常微分方程的循环神经网络单元。传统 RNN（如 LSTM、GRU）的门控参数在推理时固定不变，而 LTC 借鉴了生物神经元的膜电位动力学，让时间常数 τ 随输入和当前状态动态调整。具体而言，LTC 神经元的状态 x 由以下 ODE 描述：

$$c_m \frac{dx}{dt} = -g_{leak}(x - v_{leak}) + \sum_j w_j \sigma(x_j)(e_{rev,j} - x) \tag{2-1}$$

式中，c_m 为膜电容，g_{leak} 和 v_{leak} 分别为泄漏电导和泄漏电位，w_j 为突触权重，σ 为 sigmoid 激活函数，$e_{rev,j}$ 为第 j 条突触的反转电位。将上式整理可得等价形式 $dx/dt = -[1/\tau(x,I)] \odot x + f(x,I)$，其中 τ 不再是常数，而是关于输入 I 和状态 x 的函数——这正是" 液态时间常数" 名称的由来。

由于上述 ODE 没有解析解，实现时采用多步欧拉法进行数值离散化，默认展开 6 步。每一步依次完成三件事：计算感觉层突触对当前神经元的加权激活、计算循环层突触的加权激活（需乘以稀疏性掩码以屏蔽不存在的连接），以及按式 2-1更新神经元状态。为保证 ODE 动力学的物理合理性，训练过程中需在每次梯度更新后将 w、c_m、g_{leak} 裁剪为非负值。

2.2 神经电路策略

神经电路策略（Neural Circuit Policies, NCP）[7] 的设计灵感来自秀丽隐杆线虫（*C. elegans*）的神经连接组[8]。秀丽隐杆线虫仅有 302 个神经元，却能完成趋化、避障等复杂行为，其关键在于神经元之间高度结构化的稀疏连接模式。NCP 将这一思想迁移到人工神经网络中，定义了四层布线架构：

感觉层负责接收外部输入特征，每个输入神经元通过 f_s 条突触向下连接到中间层。中间层对感觉信号进行整合与压缩，每个中间神经元以 f_i 条突触投射到命令层。命令层是决策的核心，不仅接收中间层输入，还具有 r_c 条层内循环连接，使其能够维持短时记忆。运

动层作为输出端，每个运动神经元从命令层接收 f_m 条突触输入，生成最终的控制信号。其中 f_s、f_i、r_c、f_m 分别表示感觉扇出、中间扇出、命令循环连接数和运动扇入。

除拓扑结构外，NCP 还为每条突触赋予兴奋性（+1）或抑制性（–1）的极性属性，通过邻接矩阵统一编码。实现中，神经元编号按运动层、命令层、中间层的顺序依次排列。Lechner 等人[7] 在车道保持任务上的实验表明，仅 19 个神经元、253 个突触的 NCP 即可完成任务，而且网络的注意力会自动聚焦到道路边缘等关键区域，无需额外的可解释性方法就能直观理解网络的决策依据。

NCP 以 LTC 单元作为每个神经元的动力学模型，因此继承了 LTC 的输入自适应特性。与全连接 LTC 相比，NCP 通过稀疏邻接矩阵限制了信息传播路径。这种限制在参数量上是一种压缩，在功能上则赋予了不同层神经元明确的角色分工——感觉层编码、中间层整合、命令层决策、运动层执行——这是全连接网络所不具备的结构性可解释性。

2.3 深度 Q 网络与 Double DQN

深度 Q 网络（Deep Q-Network, DQN）[22] 用神经网络 $Q(s,a;\theta)$ 逼近最优动作值函数，是离散动作空间下深度强化学习的代表性方法。训练目标是最小化时序差分误差：

$$L(\theta)=E_{(s,a,r,s')\sim\mathscr{D}}\left[\left(r+\gamma\max_{a'}Q(s',a';\theta^{-})-Q(s,a;\theta)\right)^{2}\right] \tag{2-2}$$

其中 $\mathscr{D}$ 为经验回放缓冲区，θ^{-} 为定期从在线网络复制的目标网络参数，γ 为折扣因子。经验回放打破了连续采样之间的时间相关性，目标网络则避免了”自举目标”随训练同步漂移导致的振荡。

原始 DQN 存在 Q 值过估计的问题：max 算子同时用于选择和评估动作，会系统性地偏高。van Hasselt 等人提出的 Double DQN[23] 将两者解耦——用在线网络选择最优动作，用目标网络评估其 Q 值：

$$y=r+\gamma Q(s',\arg\max_{a'}Q(s',a';\theta);\theta^{-}) \tag{2-3}$$

在本文的场景中，NCP 的 ODE 动力学约束（权重非负、稀疏连接）使得 Q-value 估计的波动本身就比 MLP 更大，Double DQN 对训练稳定性的帮助更为明显，因此本文统一采用这一方案。

对于循环模型（LSTM、GRU、NCP），训练时不能像 MLP 那样对单步转移独立采样。本文从经验回放缓冲区中抽取长度为 8 的连续序列，序列开头将隐藏状态初始化为零向量，仅对序列最后一步计算损失，以此让隐藏状态有足够的" 预热" 步数来编码上下文信息。

2.4 进化搜索算法

NCP 的布线拓扑由 6 个离散参数决定：中间神经元数 n_i、命令神经元数 n_c、感觉扇出 f_s、中间扇出 f_i、命令层循环连接数 r_c 和运动扇入 f_m，参数之间还存在不等式约束（例如 $f_s \leq n_i$）。这类离散、带约束的组合优化问题难以用基于梯度的方法处理，因此本文选择进化搜索算法[20] 来探索布线空间。

进化搜索模拟自然选择的过程，基本流程为：随机初始化一个由若干布线配置组成的种群，评估每个个体的适应度，然后通过选择、交叉、变异产生下一代，反复迭代直至收敛。本文采用的具体算子如下：

选择阶段使用锦标赛选择，即从种群中随机抽取 k 个个体，取适应度最高者作为父代。k 值越大，选择压力越强，收敛越快但多样性损失也越大。交叉阶段对两个父代的 6 个基因逐位独立地以概率 0.5 选择来源，拼接为子代基因组。变异阶段对每个基因以概率 p_{mut} 施加高斯扰动 $\Delta \sim \mathcal{N}(0, \sigma^2)$，取整后裁剪到该基因的合法范围内。此外，每代保留适应度最高的若干个体直接进入下一代（精英保留），防止已发现的优质解在随机操作中丢失。

需要注意的是，交叉和变异可能产生违反约束的基因组合。例如，若变异后 f_s 超过了 n_i，则实际构建 NCP 布线时会出错。为此，本文在每次遗传操作后增加一步约束修复，将违约参数裁剪到合法范围。这一设计参考了带约束进化优化的常见做法。

相比可微分架构搜索方法（如 DARTS[21] 需要将离散选择松弛为连续权重），进化方法直接在离散空间上操作，不需要对搜索空间做连续化近似，实现也更为简单。

3　基于神经电路策略的可解释规划方法

3.1　整体框架

（待撰写）

3.2　神经电路策略 Q 网络设计

（待撰写）

3.3　安全感知的布线拓扑搜索

（待撰写）

4 实验与分析

4.1 实验设置

（待撰写）

4.2 基线对比实验

（待撰写）

4.3 消融实验

（待撰写）

4.4 可解释性分析

（待撰写）

5 结论与展望

（待撰写）

参考文献

[1] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Planning-oriented autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17853–17862, 2023.

[2] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Vad: Vectorized scene representation for efficient autonomous driving. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 8340–8350, 2023.

[3] Xiaosong Chen et al. Drivetransformer: Unified transformer for scalable end-to-end autonomous driving. In *International Conference on Learning Representations*, 2025.

[4] Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11621–11631, 2020.

[5] Stefan Schmoeller et al. Eu AI Act: Implications for autonomous transport. *Volvo Autonomous Solutions Technical Report*, 2025.

[6] Eloi Zablocki, Hedi Ben-Younes, Patrick Pérez, and Matthieu Cord. Explainability of deep vision-based autonomous driving systems: Review and challenges. *International Journal of Computer Vision*, 130(10):2425–2452, 2022.

[7] Mathias Lechner, Ramin Hasani, Alexander Amini, Thomas A Henzinger, Daniela Rus, and Radu Grosu. Neural circuit policies enabling auditable autonomy. *Nature Machine Intelligence*, 2(10):642–652, 2020.

[8] John G White, Eileen Southgate, J Nichol Thomson, and Sydney Brenner. The structure of the nervous system of the nematode *Caenorhabditis elegans*. *Philosophical Transactions of the Royal Society of London. B, Biological Sciences*, 314(1165):1–340, 1986.

[9] Ramin Hasani, Mathias Lechner, Alexander Amini, Lucas Liebenwein, Aaron Ray, Max Tschaikowski, Gerald Teschl, and Daniela Rus. Closed-form continuous-time neural networks. *Nature Machine Intelligence*, 4(11):992–1003, 2022.

[10] Ramin Hasani, Mathias Lechner, Tsun-Hsuan Wang, Makram Chahine, Alexander Amini, and Daniela Rus. Liquid structural state-space models. In *International Conference on Learning Representations*, 2023.

[11] Liquid AI. Lfm2 technical report. *arXiv preprint arXiv:2511.23404*, 2025.

[12] Edouard Leurent. An environment for autonomous driving decision-making. *GitHub repository*, 2018.

[13] Wenchao Sun et al. Sparsedrive: End-to-end autonomous driving with sparse scene representation. In *European Conference on Computer Vision*, 2024.

[14] Waymo Research. Emma: End-to-end multimodal model for autonomous driving. *arXiv preprint*, 2024.

[15] Xiaoyu Tian et al. Drivevlm: The convergence of autonomous driving and large vision-language models. *arXiv preprint*, 2024.

[16] Bencheng Liao et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[17] Various Authors. Carl: Large-scale reinforcement learning for autonomous driving. *arXiv preprint*, 2025.

[18] Ramin Hasani, Mathias Lechner, Alexander Amini, Daniela Rus, and Radu Grosu. Liquid time-constant networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pages 7657–7666, 2021.

[19] Makram Chahine, Ramin Hasani, Patrick Kao, Aaron Ray, Ryan P Adams, and Daniela Rus. Robust flight navigation out of distribution with liquid neural networks. *Science Robotics*, 8(77):eadc8892, 2023.

[20] Kenneth O Stanley and Risto Miikkulainen. Evolving neural networks through augmenting topologies. *Evolutionary computation*, 10(2):99–127, 2002.

[21] Hanxiao Liu, Karen Simonyan, and Yiming Yang. Darts: Differentiable architecture search. In *International Conference on Learning Representations*, 2019.

[22] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

[23] Hado Van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1), 2016.

[24] Thinklab-SJTU. Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. In *Advances in Neural Information Processing Systems*, 2024.

[25] Shahin Atakishiyev et al. Explainable artificial intelligence for safe and trustworthy autonomous driving: A systematic review. *arXiv preprint arXiv:2402.10086*, 2024.

致　谢

uu 们都看到这里了，来个三连吧！

附　录

（待补充实验核心代码）